推免雷达 · BP（2026-10-20 版）

> 一句话：把 29 所高校官网的推免公告变成「今天该你办的 3 件事」，每条都能点回原文。 不是保研指导平台，不预测录取概率；它解决的是「漏看一条公告，就少一次机会」。

---

1. 一页结论

项目	内容
产品	推免（保研）信息监控与核对工具
用户	大三下–大四上准备推免的本科生（全国每年约 15–20 万人，估算值）
核心价值	**不漏**：官网一发公告就进系统；**可信**：每条结论可回链原文；**省时**：每天只看该看的那几条
现在做到	29 所学校 / 37 个站点 / 2,646 条公告 / 557 位导师；233 条自动门禁全绿
差异化	字段三态（读到了 / 学校没写 / 我们没读到）+ 逐条原文回链 + 公开的已知边界
商业模式	C 端订阅（¥29/月）；B 端院系/机构数据服务；不卖录取概率
当前阶段	可运行、可演示的 MVP；未接入真实支付与通知渠道
需要的资源	云资源、通知渠道（邮件/微信）、3–5 所学校的深度对接、真实用户试用

---

2. 问题

2.1 用户每天面对什么

准备推免的学生要同时盯：

- 20+ 所学校的研究生院、院系官网；
- 夏令营、预推免、推免服务系统三个时间窗口；
- 截止日常常不在正文里，而在附件 PDF、表格或图片里；
- 导师方向、邮箱散落在各院系师资页。

真正的问题不是「信息少」，而是「不知道今天有没有该我动作的事」。 错过一条报名通知，代价是一整年的机会。

2.2 现有方案为什么不够

方案	问题
手动刷官网	29 所学校 × 多个栏目，必然漏；公告还会被静默修改、补附件
微信群 / QQ 群	二手信息，转发滞后，无法核对原文，广告多
现有保研 App / 公众号	多为经验帖与广告；公告常是二手转载，**点不回原文**，也无法说清哪条没抓到
学校自己	不跨校聚合，不按个人背景排序

---

3. 产品

3.1 一条完整链路

1. **填画像**：本科院校、专业、意向学校、方向（四行字）。
2. **拿推送**：每天 10 条以内，每条写明「为什么推给你」「还剩几天」。
3. **点开核对**：材料清单、联系方式、附件、正文、原文链接，一条不缺。
4. **匹配导师**：按研究方向匹配，给出邮箱与主页。
5. **生成套磁信**：模板生成，4 条引文逐条可回链原文（明确标注未接模型）。
6. **关注学院**：有新公告时站内提醒。

3.2 三个不能让步的设计

① 字段三态，绝不把「不知道」说成「没有」

状态	含义	页面措辞
`found`	读到了	直接显示日期
`absent`	正文可信，学校确实没写	「该公告未公布截止日」
`unknown`	我们没读到（扫描件/正文太短/兜底抓取）	「未能读取，请点原文核对」

当前数据：`found` 749 / `absent` 1199 / `unknown` 698。 **截止日明确且未过的只有 40 条**——这个数很小，但不是 bug：多数学校本来就不写截止日，我们不猜。

② 每条都能回原文

推送、导师、套磁信引文都带原始 URL。用户不需要相信我们，只需要点一下。

③ 空了就说空

没有对口的招生公告时，显示「今天没有」，而不是拿讲座、会议、报考点公告凑满一屏。

3.3 首页长什么样

- 顶部：数据更新于几小时前、7 天内截止 18 条、已截止/未知各多少条。

- 中部：推送卡片，标明「招生通知 / 其他 / 参考资料」。
- 右侧：按研究方向匹配的导师。
- 底部：每条都能「看原文 / 详情页」。

---

4. 技术与数据

4.1 数据管道

```
首页 → 自动发现招生栏目 → 列表翻页 → 详情正文/附件
     → 字段抽取（截止日/专业/材料/联系方式）
     → 内容分类（招生通知/目录/EMBA/其他）
     → 去重（内容指纹 + 同标题）→ 事件流 → 推送打分
```

- 抓取遵守 1–2 秒/请求的礼貌间隔，走本地缓存，不绕验证码。
- 数据写入 `.tmp` 后原子替换；条数骤降 20% 拒绝落盘（事故后加的门禁）。
- 支持增量（约 2 分钟）与全量（16–60 分钟）两种模式。

4.2 推送打分

- 四个正向维度：意向学校 0.35、专业 0.25、方向 0.20、新鲜度 0.20。
- 紧急度乘数：7 天内截止 ×2.0，8–14 天 ×1.5，15–30 天 ×1.2。
- 负向维度：EMBA/在职、报考点/考场类事务公告降权（不是隐藏）。
- 硬门槛：非招生类（讲座/会议/名单）不进首屏；目录/简章进「参考资料」区。
- 每条都输出 `why`（人话）和 `score_dims`（四维），不暴露内部加权和。

4.3 质量保障

- **233 条自动门禁**：契约形状、三态不变量、数据健康、接口行为、公网只读、请求体上限。
- 数据健康门禁：正文空壳、分类自洽、悬空事件、发布日缺失率、截止日 unknown 占比突变、标题坍塌。
- 三校外部对照：漏率从 74.1% 降到 **17.4%**（北大 155/212、川大 266/302、清华物理 19/19）。
- 其余 26 所尚未做外部对照——这是已知边界，写在 README 里。

4.4 当前指标（2026-10-19 实测）

指标	数值
公告入库	2,646 条
默认展示（剔除 153 条 junk）	2,493 条

指标	数值
招生通知（announcement）	536 条
参考资料（catalog）	293 条
EMBA / 在职	56 条
其他	1,761 条
学校 / 站点 / 院系单位	29 / 37 / 34
导师	557 位（379 位有研究方向，327 位有邮箱）
事件流	2,660 条
近 7 天发布的招生通知	1 条
近 30 天发布的招生通知	17 条
契约门禁	233 通过 / 0 失败

> 数字可用 `python collector/tools/…` 与 `server/tests/run.py` 复算； 所有对外数字都以 `data/out/` 当前快照为准，引用前重跑。

---

5. 市场

- **目标人群**：每年推免生约 15–20 万人（按推免资格高校与名额估算，待核实）；加上考研统考人群可扩展到 300 万+，但本产品第一阶段只服务推免。
- **付费意愿**：一次错过报名的机会成本远高于 ¥29/月。当前定价参照同类信息服务的低价位，属于「无脑买」区间。
- **切入顺序**：先做推免季最焦虑的 10 所目标校（用户集中、公告量适中），再横向扩校。
- **扩展路径**：推免 → 夏令营/预推免 → 考研调剂 → 海外申请；数据能力可复用到任何「官网公告 + 时间窗口」场景。

---

6. 竞争

维度	微信群/公众号	现有保研 App	推免雷达
信息新鲜度	靠人转发	二手转载	官网抓取，分钟级入库
可核对	否	常常不能	每条回链原文
跨校聚合	部分	部分	29 校 / 37 站
说清「没抓到」	不会	不会	每站新鲜度 + 失败原因公开
个人信息	群内流转	平台收集	画像只存本机/自己的访客身份

维度	微信群/公众号	现有保研 App	推免雷达
不编数据	无约束	无约束	三态 + 门禁 + 公开边界

壁垒不是模型，是数据管道 + 可信度。 抓取、分类、去重、三态、门禁这些「不性感」的工程，正是竞品最难补的部分。

---

7. 商业模式

1. **C 端订阅**：免费每天看前 10 条推送；订阅 ¥29/月，含全部推送、匹配排序、套磁信。
2. **B 端**：院系招生宣传、教育机构的数据接口（合规前提下）。
3. **开源/社区**：代码公开，数据脱敏；通过部署服务与定制采集收费。

当前支付为模拟（开通码），未接真实通道；不把「模拟支付」说成收入。

---

8. 合规与边界

- 数据来自各高校**公开官网**，遵守礼貌间隔，不绕过验证码与访问限制。
- 公开仓库与演示站**不含**考生名单、手机号等个人信息；部署版数据经过脱敏脚本处理。
- **不做**：录取概率预测、选校推荐、历年分数线——没有数据支撑的结论一律不做。
- **已知边界**（主动写在 README 与演示页）：
- 上海交大详情页为 JS 渲染，正文抓不到；
- 扫描版 PDF 无 OCR；
- 微信公众号无开放接口；
- 其余 26 所学校尚未做漏检对照；
- 单 worker、JSON 状态，暂不支持大规模并发。

---

9. 路线图

阶段	时间	目标
MVP（现在）	已完成	29 校、推送链路、导师、套磁信、233 门禁
公测	1–2 周	魔搭创空间 https 演示；3–5 所重点校深度对接；邮件提醒
增长	1–3 个月	剩余 26 校漏检对照；增至 60 校；用户试用与留存验证
商业化	3–6 个月	真实支付、院系 B 端试点、数据 API
扩展	6–12 个月	夏令营/预推免/调剂；移动端；多城市运营

---

10. 风险

风险	应对
学校官网改版 / 反爬	站点级探针 + 新鲜度告警 + 逐站对账；失败公开可见
抓取合规	只抓公开页、限速、缓存；收到通知即下架
数据错误导致误判	三态 + 置信度 + 原文回链；不替用户下结论
用户增长慢	先做单校深度，用「不漏」建立口碑
大厂复制	壁垒在长尾站点适配与数据质量，不在单点功能

11. 团队

- A：数据管道（抓取、抽取、分类、去重、质量门禁）
- B：服务层（接口、打分、状态、233 条契约门禁）
- C/F：前端（11 个页面、移动端、演示脚本）
- 统筹：交付节奏与验收；QA：只读巡检（每轮自己跑门禁、走学生画像）

> 团队采用「目录所有制 + 契约先行」协作：改动先改契约，再改实现，门禁必须绿。 这套流程本身也是可复用的交付方法。

12. 一句话收尾

这个项目最值钱的不是 2,646 条数据，是它对「不知道」的处理方式。

读不到截止日就说读不到；没有对口公告就说今天没有；判据错了就把判据和实测一起写下来，让下一个人能推翻它。 守住这三条，29 所学校也是可信的；丢了它们，200 所也只是另一堆没人敢用的数据。